

Universidad Internacional del Ecuador

Integrantes: Mateo David Castillo Machero,
Christian Alexander Salinas Ramon

Asignatura: Proyecto Integrador

Fase: Fase II - Pipeline ETL Distribuido

Fecha: 06/07/2026

1. Tema e integrantes

Número de grupo: 6

Tema asignado: Análisis de datos climáticos

Integrantes:

- Mateo David Castillo Machero
- Christian Alexander Salinas Ramon

2. Resumen de la Fase I

Durante la primera etapa del proyecto se planteó la necesidad de analizar y predecir anomalías térmicas utilizando datos climáticos históricos. El objetivo principal fue establecer las bases metodológicas para construir un sistema de análisis distribuido capaz de procesar volúmenes masivos de registros climáticos. Este proceso busca preparar el entorno óptimo para la posterior aplicación de algoritmos predictivos, lo cual permitirá a los entes gubernamentales y de planificación urbana tomar decisiones estratégicas de mitigación frente a eventos climáticos extremos.

3. Arquitectura del pipeline

El diseño del pipeline sigue una estructura secuencial orientada al procesamiento distribuido de macrodatos. Inicia con la fase de ingesta desde la fuente original en la nube. Luego pasa por una capa de limpieza orientada a garantizar la integridad estructural de la información. Posteriormente atraviesa una fase de transformación donde se curan las variables existentes y se generan nuevos indicadores meteorológicos. Finalmente termina en la capa de almacenamiento optimizado, dejando el dataset particionado y listo para el consumo del modelo de Machine Learning.

4. Proceso de ingesta de datos

La carga inicial de los datos se realizó mediante PySpark leyendo de manera distribuida los archivos históricos de la Red INMET separados por comas. El sistema infirió el esquema automáticamente y detectó un total de 27354355 registros distribuidos en 14 columnas. En este

mismo paso se aplicó una conversión inicial para mapear los códigos numéricos de error del sistema original y transformarlos en valores nulos reales para su correcto tratamiento.

5. Limpieza de datos

Se implementó un filtrado estricto para eliminar duplicados exactos y descartar aquellas filas donde la variable objetivo de temperatura estuviera vacía. La limpieza resultó en 0 registros filtrados, manteniendo las 27354355 filas intactas. Esta estrategia permitió conservar la totalidad de la información histórica, garantizando que el entrenamiento del modelo no sufra sesgos por eliminación masiva de datos.

6. Feature engineering

Durante el procesamiento de la capa Silver se creó una variable analítica nueva que no existía en el dataset original crudo.

Nombre de la variable: DEPRESION_PUNTO_ORVALHO

Lógica de creación: Se calculó restando la variable del punto de rocío a la variable de temperatura de bulbo seco.

Justificación de mejora: Esta métrica representa la depresión del punto de rocío, la cual funciona como un indicador matemático directo del estrés térmico y la sequedad ambiental. Al proporcionarle esta característica precalculada al modelo de la Fase III, el algoritmo no tendrá que inferir la relación oculta entre ambas temperaturas, permitiéndole detectar patrones de calor extremo y anomalías climáticas con un nivel de precisión muy superior.

7. Transformaciones aplicadas

Se ejecutaron tres procesos adicionales sobre los datos crudos. Primero, los nombres de las columnas se estandarizaron reemplazando los signos de puntuación por guiones bajos para evitar bloqueos de sintaxis en el motor de procesamiento. Segundo, los textos correspondientes a los nombres de los estados se pasaron a mayúsculas para evitar doble categorización por errores de tipeo. Tercero, se aplicó una normalización Z-score a la temperatura principal para estructurar la variable de entrada al modelo, lo que permite evaluar estadísticamente las desviaciones climáticas.

8. Almacenamiento optimizado

Los datos transformados se exportaron al formato columnar Parquet utilizando el algoritmo de compresión Snappy. El guardado se particionó lógicamente por la variable del año de registro para acelerar dramáticamente las consultas futuras. El archivo definitivo se alojó en un directorio estructurado en la nube para garantizar su disponibilidad inmediata en la siguiente fase de modelado.

9. Validaciones de calidad

La función de auditoría diseñada para el pipeline confirmó que ingresaron 27354355 filas en la etapa de ingesta y salieron exactamente las mismas 27354355 filas al final del almacenamiento. El proceso de enriquecimiento de datos amplió la estructura original de 14 a 16 columnas útiles. El tiempo total de escritura distribuida en el clúster fue de 512.70 segundos, demostrando un alto nivel de eficiencia al manipular millones de registros.

10. Evidencias

El desarrollo analítico completo se encuentra respaldado en el cuaderno ejecutable entregado junto a este informe. En dicho entorno de desarrollo se pueden observar los bloques de código y los reportes numéricos que validan las transformaciones estadísticas paso a paso. Adicionalmente, el directorio virtual del grupo contiene el dataset curado, particionado y verificado.

11. Plan para la Fase III

Tipo de modelo: Se aplicará un modelo predictivo de regresión utilizando el algoritmo Random Forest Regressor de la librería Spark MLlib.

Features seleccionadas: Las variables de entrada para el entrenamiento serán la temperatura normalizada, la depresión del punto de rocío, la humedad, la radiación, el mes del año y la velocidad del viento.

Variable objetivo: El sistema predecirá la temperatura de bulbo seco.

Métrica de evaluación: Se empleará el Error Cuadrático Medio RMSE para cuantificar el margen de error real de las predicciones y el coeficiente R cuadrado para validar la varianza explicada por el modelo.

Justificación del modelo: El comportamiento climático es un fenómeno altamente no lineal. Se seleccionó Random Forest Regressor porque su arquitectura basada en múltiples árboles de decisión captura con total precisión las interacciones complejas entre nuestra nueva métrica de estrés térmico, la radiación y la velocidad del viento. A nivel técnico, al ser un algoritmo nativamente distribuido en Spark, asegura el entrenamiento simultáneo sobre los 27 millones de registros sin saturar la memoria del clúster, garantizando predicciones robustas incluso frente a picos atípicos de calentamiento global.

12. Conclusiones de la fase

El pipeline construido cumple rigurosamente con los requerimientos técnicos estipulados para procesar Big Data climático. La implementación mediante Spark permitió realizar transformaciones lógicas complejas y cálculos estadísticos avanzados sobre más de 27 millones de registros en un tiempo de 512.70 segundos. El dataset resultante se encuentra completamente depurado, enriquecido con métricas de estrés térmico y optimizado estructuralmente en 16 columnas. Esto asegura un rendimiento estable y altamente escalable para el algoritmo Random Forest Regressor que se ejecutará en la Fase III.

Bibliografía o fuentes utilizadas

Apache Spark. 2024. PySpark Documentation. Apache Software Foundation.

Instituto Nacional de Meteorología INMET. 2024. Banco de Datos Meteorológicos. Ministerio da Agricultura e Pecuaria.

Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., e Stoica, I. 2016. Apache Spark: a unified engine for big data processing. Communications of the ACM.