

Universidad Internacional del Ecuador

Integrantes: Mateo David Castillo Machero,
Christian Alexander Salinas Ramon

Asignatura: Practicas y Herramientas de Big Data

Fase: Fase II - Pipeline ETL Distribuido

Fecha: 06/07/2026

1. Tema e integrantes

Número de grupo: 6

Tema asignado: Análisis de datos climáticos

Integrantes:

- Mateo David Castillo Machero
- Christian Alexander Salinas Ramon

2. Resumen de la Fase I

Durante la primera etapa del proyecto se planteó la necesidad de analizar y predecir anomalías térmicas utilizando datos climáticos históricos. El objetivo principal fue establecer las bases metodológicas para construir un sistema de análisis distribuido capaz de procesar volúmenes masivos de registros climáticos. Este proceso busca preparar el entorno óptimo para la posterior aplicación de algoritmos predictivos, lo cual permitirá a los entes gubernamentales y de planificación urbana tomar decisiones estratégicas de mitigación frente a eventos climáticos extremos.

3. Arquitectura del pipeline

El diseño del pipeline sigue una estructura secuencial orientada al procesamiento distribuido de macrodatos. Inicia con la fase de ingesta desde la fuente original en la nube. Luego pasa por una capa de limpieza orientada a garantizar la integridad estructural de la información. Posteriormente atraviesa una fase de transformación donde se curan las variables existentes y se generan nuevos indicadores meteorológicos. Finalmente termina en la capa de almacenamiento optimizado, dejando el dataset particionado y listo para el consumo del modelo de Machine Learning.

4. Proceso de ingesta de datos

La carga inicial de los datos se realizó mediante PySpark leyendo de manera distribuida los archivos históricos de la Red INMET separados por comas. El sistema infirió el esquema automáticamente y detectó un total de 27354355 registros distribuidos en 14 columnas. En este

mismo paso se aplicó una conversión inicial para mapear los códigos numéricos de error del sistema original y transformarlos en valores nulos reales para su correcto tratamiento.

5. Limpieza de datos

Se implementó un filtrado estricto para eliminar duplicados exactos y descartar aquellas filas donde la variable objetivo de temperatura estuviera vacía. La limpieza resultó en 0 registros filtrados, manteniendo las 27354355 filas intactas. Esta estrategia permitió conservar la totalidad de la información histórica, garantizando que el entrenamiento del modelo no sufra sesgos por eliminación masiva de datos.

6. Transformaciones aplicadas

Se ejecutaron cuatro procesos fundamentales sobre los datos crudos. Primero, los nombres de las columnas se estandarizaron reemplazando los signos de puntuación por guiones bajos para evitar bloqueos de sintaxis en el motor de procesamiento. Segundo, los textos correspondientes a los nombres de los estados se pasaron a mayúsculas para evitar doble categorización por errores de tipeo. Tercero, se aplicó ingeniería de características creando la variable `DEPRESION_PUNTO_ORVALHO` restando la temperatura del punto de rocío. Esta nueva métrica de estrés térmico registró una media de 8.11, un valor mínimo de -21.8 y un máximo de 42.8. Cuarto, se aplicó una normalización Z-score a la temperatura principal para estructurar la variable de entrada al modelo.

7. Almacenamiento optimizado

Los datos transformados se exportaron al formato columnar Parquet utilizando el algoritmo de compresión Snappy. El guardado se particionó lógicamente por la variable del año de registro para acelerar dramáticamente las consultas futuras. El archivo definitivo se alojó en un directorio estructurado en la nube para garantizar su disponibilidad inmediata en la siguiente fase de modelado.

8. Validaciones de calidad

La función de auditoría diseñada para el pipeline confirmó que ingresaron 27354355 filas en la etapa de ingesta y salieron exactamente las mismas 27354355 filas al final del almacenamiento. El proceso de enriquecimiento de datos amplió la estructura original de 14 a 16 columnas útiles. El tiempo total de escritura distribuida en el clúster fue de 512.70 segundos, demostrando un alto nivel de eficiencia al manipular millones de registros.

9. Evidencias

El desarrollo analítico completo se encuentra respaldado en el cuaderno ejecutable entregado junto a este informe. En dicho entorno de desarrollo se pueden observar los bloques de código y los reportes numéricos que validan las transformaciones estadísticas paso a paso. Adicionalmente, en el google Drive contiene el dataset curado, particionado y verificado.

10. Conclusiones de la fase

El pipeline construido cumple rigurosamente con los requerimientos técnicos estipulados para procesar Big Data climático. La implementación mediante Spark permitió realizar transformaciones lógicas complejas y cálculos estadísticos avanzados sobre más de 27 millones de registros en un tiempo de 512.70 segundos. El dataset resultante se encuentra completamente depurado, enriquecido con indicadores de estrés térmico y optimizado estructuralmente en 16 columnas. Esto asegura un rendimiento superior y estable para los algoritmos predictivos que se implementarán en la Fase III.

Bibliografía

Apache Spark. 2024. PySpark Documentation. Apache Software Foundation.

Instituto Nacional de Meteorología INMET. 2024. Banco de Datos Meteorologicos. Ministerio da Agricultura e Pecuaria.

Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., e Stoica, I. 2016. Apache Spark: a unified engine for big data processing. Communications of the ACM.